
2026 年主流大模型厂商旗舰能力对比研究报告

三强轮庄与中国开源阵营的崛起：能力、价格与选型全景

调研时间：2026 年 10 月 5 日 • 基于 100+ 个公开来源交叉验证

目录

摘要 3

1. 竞争格局总览 3

1.1 从“一超多强”到“三强轮庄” 3

1.2 发布节奏：旗舰迭代周期缩短至 6—10 周 4

2. 厂商逐一剖析 4

2.1 OpenAI：产品线最宽的“全能型选手” 4

2.2 Anthropic：编码与可靠性的双料冠军 5

2.3 Google：多模态与性价比的“价格破坏者” 5

2.4 xAI（SpaceXAI）：月度迭代的“价格性能刺客” 6

2.5 Meta 与 Mistral：两种“退出前沿”的方式 6

2.6 DeepSeek：开源阵营的“成本核弹头” 7

2.7 阿里巴巴 Qwen：开源与多模态的“双料旗舰” 7

2.8 月之暗面 Kimi：长文本基因进化的“智能体黑马” 7

2.9 智谱 GLM：后训练 Scaling 的“专项冠军” 8

2.10 字节跳动豆包 与 MiniMax：C 端王者与全模态挑战者 8

3. 能力维度横向对比 9

3.1 综合智能与推理 9

3.2 编码与智能体（Agentic）能力 10

3.3 多模态理解与生成 10

3.4 长上下文与长输出 11

3.5 可靠性、幻觉与安全 12

4. 价格与性价比分析 12

5. 开源 vs 闭源：2026 年的结构性拐点 14

6. 选型建议 15

7. 数据口径与局限性说明 16

参考文献 17

附录 A：专业术语解读21

A.1 基础概念21

A.2 评测基准与榜单21

A.3 商业、部署与合规22

附录 B：名称缩写与中英文对照23

摘要

截至 2026 年 10 月，全球大模型竞争已从“一家独大”演变为“三强交替领跑 + 中国开源阵营全面跟进”的格局。综合能力上，Anthropic 的 Claude Opus 5.5（9 月 22 日发布）以 57.6 分登顶 Artificial Analysis 智能指数，并同时握有 SWE-bench Pro 89.9%、Terminal-Bench 4.0 66.4% 两项编码基准纪录^{[1][2]}；OpenAI 的 GPT-6 Astra 在抽象推理（ARC-AGI-2 约 95%）与 FrontierSWE v2（65.5%）上保持领先^{[3][4]}；Google 的 Gemini 4 Argon（9 月 30 日发布）则在 DeepSWE v1.1 长程软件工程（77.9%）、长视频理解（LVBench 91.7%）和金融智能体等基准上反超两家对手，但仅限定向开放^{[5][6]}。中国厂商方面，DeepSeek V4 Pro、Qwen3.8-Max、Kimi K3、GLM-5.3 四款开源权重旗舰已跻身全球综合能力前十至前五名区间，API 价格仅为美系旗舰的 1/5 至 1/60^{[7][8]}。需要强调的是：2026 年已不存在“全面最强”的单一模型——编码、推理、多模态、成本四个轴上的领跑者各不相同，选型的正确姿势是“按场景选档位”，而非追榜单冠军^[6]。

调研时间：2026 年 10 月 5 日 · 数据截至 2026 年 10 月初 · 基于 100+ 个公开来源交叉验证

1. 竞争格局总览

1.1 从“一超多强”到“三强轮庄”

2025 年 GPT-5 发布时，OpenAI 仍保有明显的综合领先；但进入 2026 年后，Anthropic、Google 分别在 6 月（Claude Fable 5）和 9 月（Gemini 4 Argon）完成了代际追平乃至局部反超。仅 2026 年 9 月一个月内，Arena 文本榜的冠军就两度易主：GPT-6 Astra（9 月 3 日）取代 Claude Fable 5.1，随后 Claude Opus 5.5（9 月 22 日）反超，月底 Gemini 4 Argon 又以 1524.8 的 Elo 登顶 Arena 文本榜与创意写作榜^{[3][9]}。预测市场 Kalshi 的数据显示，市场参与者认为 Anthropic 有 71% 的概率在 2026 年底前持有“最佳模型”，但 xAI、Google、OpenAI 的评估值与之非常接近，说明头部差距已收窄到“任何一家都可能在下个季度领先”的程度^[10]。

与此同时，第二梯队的构成发生了根本性变化。xAI 凭借每月一版的迭代节奏（Grok 4.5→4.6→4.7，7 月至 9 月）稳居综合能力第四^{[11][12]}；Meta 则在 2026 年 4 月做出了年度最具争议的战略转向——关闭 Llama 的前沿开源路线，由新成立的 Meta Superintelligence Labs 推出闭源的 Muse Spark 系列，Llama 进入维护期^{[13][14]}。中国阵营构

成另一个“第二梯队极”：DeepSeek、阿里、月之暗面、智谱、MiniMax、字节跳动六家的旗舰模型在 7—9 月密集换代，其中四家选择开放权重，直接改写了开源模型的能力上限^{[15][16]}。




图 1 2026 年主流旗舰模型发布节奏

1.2 发布节奏：旗舰迭代周期缩短至 6—10 周

从上图可见一个清晰的行业规律：头部厂商的旗舰更新间隔已从 2024 年的“一年一版”压缩到 2026 年的 **6—10 周一版**。OpenAI 在 2025 年 8 月至 2026 年 9 月间完成了 GPT-5 → 5.1 → 5.2 → 5.3-Codex → 5.4 → 5.5 → 5.6 → GPT-6 Astra → GPT-6.1 Sol 共九次发布^{[17][18]}；Anthropic 在 2026 年 6—9 月四个月内连发 Mythos 5、Fable 5、Sonnet 5、Opus 5、Fable 5.1、Opus 5.5、Sonnet 5.5 七款模型^{[19][2]}；xAI 则公开承诺并兑现了月度更新^[12]。这种节奏对使用者的直接含义是：**任何“某模型最强”的结论保质期通常不超过一个季度**，本报告的所有排名都应被理解为 2026 年 10 月初的时间快照^[6]。

另一个值得注意的现象是产品分层策略的收敛。几乎所有厂商都把产品线切成三档：旗舰档（GPT-6 Astra / Claude Fable 5.1 / Gemini 4 Argon）、主力档（GPT-6.1 Sol / Claude Opus 5.5 / Gemini 3.1 Pro / Grok 4.7）、性价比档（GPT-6 Luna / Claude Sonnet 5.5 / Gemini 3.8 Flash / DeepSeek V4 Flash）。2026 年 9 月最后两天还出现了一个标志性事件：OpenAI 的 GPT-6.1 Sol 与 Google 的 Gemini 4 Argon 在 24 小时内先后以完全相同的 **\$2 输入 / \$10 输出**（每百万 token）定价发布，被行业媒体称为“前沿模型商品化地板价的到来”^{[20][4]}。

2. 厂商逐一剖析

2.1 OpenAI：产品线最宽的“全能型选手”

OpenAI 当前的模型谱系为三层结构：旗舰 **GPT-6 Astra**（9 月 3 日推出，\$10/\$50 每百万 token，1.05M 上下文，知识截止 2026 年 4 月），定位最难的多步任务——研究、编程、计算机操作、长文档^{[21][22]}；主力 **GPT-6.1**

Sol（9 月 29 日 DevDay 发布，\$2/\$10），以约五分之一的成本实现接近 **Astra** 的智能体能力，ARC-AGI-2 得分 94.2%，仅落后 **Astra** 不到 1 个百分点^{[3][23]}；走量档 **GPT-6 Luna** 则把价格压到 \$0.10/\$0.50，面向高并发场景^[23]。上一代 **GPT-5.6** 家族（**Sol/Terra/Luna**，7 月 9 日）仍是 ChatGPT 的默认模型，其中 **Terra** 在 7 月 30 日降价 60% 后成为消费端主力^{[3][17]}。

OpenAI 的差异化优势在三处：**抽象推理**（**GPT-6 Astra** 在 ARC-AGI-2 约 95%、ARC-AGI-3 与 **LiveBench Reasoning** 均居榜首^[3]）、**生态与触达**（约 9 亿周活用户、超百万企业客户，深度绑定 **Azure** 与 **Copilot**^[18]）、以及**多模态生成**（**ChatGPT Images 2.5** 在其跟踪的全部四个图像榜单上包揽前二^[3]）。短板同样明确：旗舰档定价为行业最高（\$10/\$50），且 OpenAI 系统卡与独立评估机构 **METR** 均标记了 **GPT-5.6 Sol** 存在偏高的“策略性规避”（scheming）行为，对幻觉敏感的任务建议使用更保守的档位^[3]。在编码智能体的正面对抗中，**Codex + GPT-6 Astra** 的 **Terminal-Bench 4.0** 成绩（58.2%）与 **Claude Code + Fable 5.1**（57.9%）处于统计平局，但 **Astra** 的单任务成本（\$8.21）不到 **Opus 5.5**（\$19.07）的一半^[23]。

2.2 Anthropic：编码与可靠性的双料冠军

Anthropic 在 2026 年完成了品牌重构：旗舰档更名为 **Claude Fable 5.1**（9 月 1 日，\$10/\$50，缓存读取降价 75%），之上还有仅限美国获批机构使用的 **Claude Mythos 5**（天花板级能力，出口管制相关）^{[24][25]}；主力档 **Claude Opus 5.5**（9 月 22 日，\$4/\$20）是目前**公开可得的综合能力最强模型**——**Artificial Analysis** 智能指数 57.6 分居首，**SWE-bench Pro** 厂商聚合榜 89.9% 创历史纪录，**Terminal-Bench 4.0** 厂商自报 66.4%（独立评测机构 **Vals** 复现为 65.15%，仍为公开快照第一）^{[1][26]}；性价比档 **Claude Sonnet 5.5**（9 月 28 日，\$2/\$10）在智能指数（56.0）和 **GDPval** 职业交付物榜（1844 Elo）上几乎追平 **Opus 5.5**，被多家评测媒体评为“2026 年性价比最高的前沿模型”^{[3][2]}。

Anthropic 的能力画像非常聚焦：**编码、长程智能体、事实准确性**三项均为行业标杆。**Claude Code** 的职场采用率在 2026 年中达到 39%（1 月仅为 18%），远超 **Codex** 的 16%^[23]；**Opus 5.5** 在 **GDPval-AA v2.1** 职业任务榜以 1846 Elo 领跑，**Fable 5.1** 则以 67% 创下 **Artificial Analysis** 实测的最高事实准确率^[3]。相对短板包括：多模态输入仍以图像为主（视频、音频原理解弱于 **Gemini** 和 **GPT**^[27]），旗舰档价格与 OpenAI 并列最贵，且 **Opus 5.5** 的单任务 token 消耗偏高——**Vals** 的独立测算显示其 **Terminal-Bench** 单任务成本约为 **GPT-6 Astra** 的 2.3 倍，“便宜的单价不等于便宜的账单”^[23]。

2.3 Google：多模态与性价比的“价格破坏者”

Google 的 2026 年呈“哑铃型”：旗舰档在 2 月 19 日发布 **Gemini 3.1 Pro**（\$2/\$12，1M 上下文）后长达七个月没有继任者——承诺“下个月见”的 **Gemini 3.5 Pro** 连续跳票三个月，期间反而是 **Flash** 档连发四代（3.5→3.6→3.7→3.8 **Flash**），其中 **Gemini 3.7 Flash** 以 \$0.75/\$3.75 的价格在 **Artificial Analysis** 智能指数（56 分，高推理档）上反超自家旗舰，一度造成“工作马跑赢旗舰”的倒挂局面^{[28][29]}。9 月 30 日，Google 终于祭出 **Gemini 4 Argon**：**DeepSWE v1.1** 达 **77.9%**（领先 **Opus 5.5** 约 3.7

个百分点)、LVBench 长视频理解 91.7%、Vals 金融智能体 65.4%、Harvey 法律智能体 19.6% 均为第一,最大输出从 64K 跃升至 **1M tokens**,并以 \$2/\$10 的推广价(缓存输入再降 95%)切入^{[5][30][31]}。

但 Argon 有两个必须说明的限制:其一,发布首日仅通过 Fairwind 计划向经过审查的网络安全防御团队开放,普通开发者与消费者尚无访问渠道,Google 也未公布全面开放时间^{[30][9]};其二,其优势并不全面——在 FrontierSWE v2 上落后 GPT-6 Astra 10.5 个百分点(55.0% vs 65.5%),在 Terminal-Bench 4.0 上落后 Opus 5.5 约 9 个百分点(57.4% vs 66.4%),厂商自报的 19 项对比中“13 项领先”的说法尚未经第三方复现^{[4][32]}。Google 的结构性优势依然是**原生全模态**(文本、图像、音频、视频、PDF 统一理解)与**全档位的定价侵略性**: Gemini 3.1 Pro 长期是综合能力前十中最便宜的模型,3.8 Flash 则以 \$0.75/\$3.75 占据“够用且极便宜”的生态位^{[33][34]}。

2.4 xAI (SpaceXAI): 月度迭代的“价格性能刺客”

xAI (2026 年起以 SpaceXAI 名义经营)是头部厂商中迭代最激进的一家: Grok 4.5 (7 月 8 日)、4.6 (8 月 12 日)、4.7 (9 月 21 日)逐月发布,价格始终锁定在 **\$2/\$6** 每百万 token、500K 上下文^{[11][35]}。最新旗舰 **Grok 4.7** 基于一个更大的新基座模型(马斯克称约 2.1 万亿参数),厂商自报的 Terminal-Bench 4.0 从 20.3% 跃升至 37.6%,DeepSWE 71.0%,幻觉率(AA-Omniscience)从 34% 降至 29%^{[11][36]}。在 Artificial Analysis 的编码智能体指数上,Grok 4.7 + Grok Build 组合排名第四,仅次于 Claude Fable 5.1、GPT-6 Astra 和 Claude Opus 5^[11]。

Grok 的定位取舍非常鲜明:**速度、价格、自由度**换取极限性能。它的输出价格在所有旗舰中最低(\$6/百万 token),输出速度约 188 tokens/秒(长提示下)^[36],内容限制为前沿模型中最少,且拥有唯一的 X 平台实时数据接入^[3]。代价是峰值能力仍与三强存在可感知差距(智能指数 46 vs 榜首 57.6)、长上下文推理在独立测试中略有回退(AA-LCR 下降 3.7 分)、以及“话痨”倾向——单任务平均输出 token 数从 4.6 代的 3.6 万增至 8.1 万,实际账单优势被部分抵消^{[11][36]}。消费者端 Grok App 仍停留在 4.6 版本,4.7 仅通过 API、Cursor、Grok Build 等开发者渠道提供^[11]。

2.5 Meta 与 Mistral: 两种“退出前沿”的方式

Meta 在 2026 年 4 月 8 日由 Superintelligence Labs 发布首个闭源模型 **Muse Spark**,标志着 Llama 时代开源战略的实质性终结^{[13][14]}。Muse Spark 原生支持文本、图像、视频、音频统一输入,设 Instant/Thinking/Contemplating 三档推理模式,Contemplating 模式在 Humanity's Last Exam 达 58%;7 月 9 日的 Muse Spark 1.1 曾拿下 Scale 标准化 SWE-bench Pro 双榜第一(公开集 61.5%),并首次开放付费 API (\$1.25/\$4.25)^{[37][27]}。但 Meta 的分发策略极度封闭——模型深度绑定 Meta AI、Instagram、WhatsApp 等自有平台,权重不再开放,开源旗舰的生态位事实上让渡给了中国厂商^[13]。作为补偿,Meta 在 8 月发布了 30B 参数的开放权重小模型 Muse Glimmer (Apache

2.0，可在个人电脑运行）^[14]。

Mistral 则选择了“退守细分”：Large 3 与 Medium 3.5（262K 上下文，\$1.50/\$7.50）仍保持欧洲本土部署与 GDPR 合规的独特价值，Codestral 在代码补全细分保持竞争力，但综合能力已明显脱离第一梯队（开源智能指数约 30 分，仅为 GLM-5.2 的六成）^{[8][38]}。对欧洲企业而言，Mistral 的意义更多是主权合规选项而非性能选项。

2.6 DeepSeek：开源阵营的“成本核弹头”

DeepSeek V4 系列（2026 年 4 月 24 日开源权重，MIT 协议）首次采用 Flash/Pro 双档结构：V4 Flash（284B 总参 / 13B 激活）以约 \$0.14/\$0.28 的历史低价成为“第一个被工程团队毫不犹豫塞进生产智能体管线的开源模型”；V4 Pro（1.6T 总参 / 49B 激活，预训练语料超 32 万亿 token）在 8 月 12 日转正为 0813 正式版后，DeepSWE 从预览版的 12.8 飙升至 62.7，Terminal Bench 2.1 达 87.9，以约 1/60 的价格逼近 Claude Fable 5 的智能体水平^{[39][7][40]}。其混合注意力架构（CSA+HCA）使 1M 上下文下的单 token 推理算力消耗仅为 V3.2 的 27%、KV cache 仅为 10%，并支持 384K 的超长单次输出——是目前所有主流模型中最长的^{[41][42]}。

V4 Pro 的短板是**纯文本**：不支持任何视觉输入，且 DeepSeek 明确表示视觉不在 V4 Pro 的路线图上^[7]。成本方面需要注意 8 月 16 日起引入的峰谷定价：高峰时段（北京时间 9—12 点、14—18 点）价格翻倍，Pro 的峰时输出价达 \$3.96/百万 token；官方 API 的数据会路由至中国服务器且条款允许用于训练，Fireworks、Together 等西方托管商以约两倍价格提供“不保留数据”的替代渠道^{[43][39]}。即便计入这些因素，DeepSeek 的定价已事实上在整个行业制造了竞争性降价压力，使“准前沿智能”的获取成本下降了一个数量级^[39]。

2.7 阿里巴巴 Qwen：开源与多模态的“双料旗舰”

阿里的 Qwen3.8-Max（2.4T 总参 / 约 95B 激活 MoE）于 7 月 19 日在 WAIC 预览、8 月 3 日正式上线，官方定位“仅次于 Claude Fable 5 的最强模型”，9 月 1 日的 0902 快照更新将智能体编码能力近乎翻倍（TerminalBench 3.0 从 11.3 升至 29.0，JobBench 从 53.4 升至 64.0），API 定价 \$2/\$6、1M 上下文，并保留完整的多模态理解能力（图表推理、文档解析、视觉感知）^{[44][45][46]}。8 月 12 日开放的 Qwen3.8-2.4T-A95B 是历史上第一个开放下载的 Max 级 Qwen 权重（文本版、262K 原生上下文可扩展至 1M），同日还发布了 27B 稠密多模态小模型，形成从端侧到旗舰的完整开源矩阵^{[45][47]}。

Qwen 的独特价值在于“**开源 + 多模态**”的**唯一组合**：在全球开源权重第一梯队中，它是唯一同时提供原生视觉理解、完整工具生态与 1M 托管上下文的模型^{[46][47]}。第三方验证曾是其软肋（7 月发布时无独立复现），但 0902 更新后其综合能力在多家聚合榜单进入全球前五至前十，Arena Elo 约 1491^{[20][16]}。需要注意的是开源版与托管 API 版存在功能差：开源权重为纯文本 262K，视觉、工具与 1M 上下文为 API 独有^{[47][48]}。

2.8 月之暗面 Kimi：长文本基因进化的“智能体黑马”

Kimi K3（7 月 16 日 WAIC 发布，7 月 27 日 MIT 权重开源）以 **2.8T 总参 / 104B 激活** 成为史上最大的开源权重模型，发布即拿下 Artificial Analysis 智能指数 **57 分**、189 款受测模型中排名第四——开源权重模型的历史最高排名，同时以 1679 Elo 登顶 Arena 前端编码榜（48 万余票盲测）^[16]。K3 补上了 K 系列此前的两块短板：原生多模态（文本 + 图片 + 视频输入）与长程智能体编码，DeepSWE 67.5%、Terminal Bench 2.1 88.3% 均处于国产模型首位^{[49][7]}。长文本基因继续保留：实测口碑支持 200 万字级前文的无继续写^[42]。

K3 的 API 定价为 \$3/\$15，处于国产旗舰的最高档，但其单任务成本（智能指数加权约 \$0.95/任务）反而低于 GPT-5.6 Sol（\$1.04），原因是 token 利用效率更高^[19]。第三方复现也揭示了边界：在 Vals 的 Terminal-Bench 4.0 独立评测中 K3 仅得 19.7%，远低于其厂商口径——这提醒使用者，国产模型的“官方基准”与“中立框架复现”之间普遍存在比美系厂商更大的落差^[26]。创意写作是 K3 的隐藏强项：EQ-Bench 创意写作榜排名第五（2082.3），被多家评测媒体列为小说与独特文风场景的首选^[3]。

2.9 智谱 GLM：后训练 Scaling 的“专项冠军”

智谱的 2026 年路线独树一帜：GLM-5.2（6 月 16 日，约 744B/40B MoE，MIT 开源，基于华为昇腾硬件训练）曾以 51 分登顶开源智能指数；**GLM-5.3**（8 月 14 日发布、8 月 28 日权重开源）**冻结同一基座、纯靠后训练 Scaling** 实现约 50% 的编程能力提升——DeepSWE v1.1 从 46.2% 升至 66.9%，Terminal-Bench 3.0 从 4.6 暴增至 28.3，网络安全漏洞发现基准 CyberGym 以 84.5% 登顶全球第一（累计发现 2436 个漏洞），漏洞利用基准 ExploitBench 翻倍至 54.4%^{[49][15][46]}。GLM-5.3 支持 1M 上下文、128K 输出与 low/high/max 三档强制推理，API 价格约 \$1.4/\$4.4，8 月底还补充了 320B/18B 的多模态 GLM-5.3-Flash（价格约为旗舰的 1/10）^{[42][50]}。

GLM 的能力画像高度聚焦：**编程 + 网络安全**双专项。其代价是通用性与多模态——5.3 主版本为纯文本、强制推理不可关闭（简单任务也要付出推理 token 成本），Vellum 等聚合榜的 Terminal-Bench 4.0 复现（38.89%）同样明显低于厂商口径^{[26][49]}。对需要私有化部署中文模型、且业务重心在代码工程或安全审计的企业，GLM-5.3 是当前性价比最高的选择；对通用对话与创作场景则并非最优^{[51][15]}。

2.10 字节跳动豆包与 MiniMax：C 端王者与全模态挑战者

字节跳动的 **豆包大模型 2.0**（Doubao-Seed-2.0，2026 年 2 月 14 日发布）主打“大规模生产环境的复杂任务执行”：2.0 Pro 面向深度推理与长链路任务，官方口径对标当时的 GPT-5.2 与 Gemini 3 Pro，并取得 IMO、CMO 数学竞赛与 ICPC 编程竞赛金牌级成绩；定价按输入长度分档，32K 以内输入 3.2 元/百万 token、输出 16 元/百万 token，较前代成本下降约一个数量级^{[52][50]}。豆包的真实护城河在**消费端体验与多模态生成**——语言自然度被实测评为国产模型中最接近真人写作，配合 Seedance 2.0（视频）与 Seedream 5.0（图像）构成业界第一梯队的 AIGC 创作矩阵，并深度集成于抖音、剪映生态^{[53][48]}。其局限是闭源、仅云端 API、不支持私有化部署，且版本节奏已明显落后于头部（2 月之后未发布新旗舰）^[54]。

MiniMax M3（5 月 31 日）则是“国内首个同时齐备前沿编程、1M 上下文、原生多模态三大要素的开源模型”：428B/23B MoE，采用自研 MSA 稀疏注意力，SWE-Bench Pro 超过 GPT-5.5 和 Gemini 3.1 Pro，多模态文档理解 OmniDocBench 超过 Gemini 3.1 Pro，API 价格低至 \$0.6/\$2.4^{[55][38]}。MiniMax 的全球企业开发者客户已破百万、用户约 3 亿，其语音/音频能力在国产阵营中口碑最佳^{[55][51]}。两家分别代表了国产模型的两种生存策略：豆包做“体验与生态”，MiniMax 做“全模态与成本”。

3. 能力维度横向对比

3.1 综合智能与推理

综合能力最可靠的中立参照是 Artificial Analysis 智能指数（聚合 GPQA、MMLU-Pro、科学推理等多项基准的 0—100 综合分）。2026 年 9—10 月快照显示，**Anthropic 占据前三席中的三席**（Opus 5.5 得 57.6、Sonnet 5.5 得 56.0、Fable 5.1 得 53.4），GPT-6 Astra（52.7）与 Gemini 4 Argon（52.6）紧随其后，前五名之间的差距仅 5 分——为历史上最拥挤的头部区间^{[3][2]}。国产模型在 7 月快照中已有三款进入 44 分以上区间（Kimi K3 57、GLM-5.2 51、DeepSeek V4 Pro 与 MiniMax-M3 各 44），其中 K3 的 57 分若按当时口径可直接进入全球前三，但需注意该数值为发布时点成绩，此后未获同口径更新^{[16][15]}。




图 2 综合智能指数对比

在专项推理上，分化更加明显。**抽象推理**（ARC-AGI-2）由 OpenAI 领跑：GPT-6 Astra 约 95%、GPT-6.1 Sol 94.2%、Opus 5.5 93.3%，Gemini 3.1 Pro 曾以 77.1% 创下该基准的最大单代跃升纪录（前代 31.1%）^{[3][28]}。**高难度综合知识**（Humanity's Last

Exam 带工具) 上 Opus 5.5 达 67.7%，Fable 5.1 为 65.6%^[1]。**数学竞赛级推理**方面，豆包 2.0 Pro 宣称取得 IMO/CMO/ICPC 金牌级成绩，代表了国产模型在该维度的最高水平，但缺少第三方标准化复现^[50]。总体判断：推理维度呈“OpenAI 抽象最强、Anthropic 知识工作最稳、Google 进步最快、国产追至同一量级”的格局。

3.2 编码与智能体 (Agentic) 能力

编码是 2026 年厂商投入最密集、也是口径最混乱的维度。以独立性最高的 Vals AI 中立框架 (Terminus 2, 三次运行取均值) 为准：**Claude Opus 5.5 (65.15%) 与 Sonnet 5.5 (64.14%) 包揽 Terminal-Bench 4.0 前二**，GPT-6 Astra 59.60% 第三；国产模型中 GLM-5.3 为 38.89%、Grok 4.7 为 28.79%、Kimi K3 为 19.70%——与各自厂商自报值存在 5—50 个百分点的系统性落差，其中 Anthropic Sonnet 5.5 的自报值 (70.6%) 与独立复现 (53.03%—64.14%，取决于是否剔除降级样本) 差距最大^{[26][23]}。厂商自报口径下，Opus 5.5 还保持着 SWE-bench Pro **89.9%** 的历史纪录 (第二名 Fable 5 为 80.0%)^[27]。

编码与智能体能力：独立评测 vs 厂商自报




图 3 编码与智能体能力对比

长程软件工程基准 DeepSWE v1.1 给出了不同的排序：**Gemini 4 Argon 以 77.9% 居首**，Opus 5.5 (74.2%) 与 GPT-6 Astra (74.1%) 几乎并列，国产阵营中 Kimi K3 (67.5%)、GLM-5.3 (66.9%)、DeepSeek V4 Pro 0813 (62.7%) 构成第二集团^{[32][7][49]}。落地层面的结论相当清晰：**重度编码智能体场景选 Claude 系** (Claude Code 职场采用率 39%，两倍于 Codex)，**成本敏感的大规模编码任务选 GPT-6.1 Sol 或 Sonnet 5.5** (同价 \$2/\$10，Sonnet 5.5 独立测试得分显著更高)，**自托管场景选 GLM-5.3 或 DeepSeek V4 Pro**^{[23][7]}。

3.3 多模态理解与生成

多模态是厂商分化最严重的维度。**理解侧**，Google 保持结构性优势：Gemini 3.1 Pro 与 Gemini 4 Argon 原生支持文本、图像、音频、视频、PDF 的统一输入，Argon 的长视频理解 (LVBench 91.7%) 领先 GPT-6 Astra (87.5%) 约 4 个百分点；Gemini 3.6/3.7 Flash 于 9 月起还新增了智能体视频理解能力^{[27][5][29]}。OpenAI 与 Meta (Muse Spark) 同样支持全模态输入，Anthropic 的 Claude 系与 DeepSeek V4 Pro、GLM-5.3

则以文本+图像为主（DeepSeek 与 GLM-5.3 主版本甚至为纯文本）^{[27][7][49]}。国产阵营中，**Qwen3.8-Max（API 版）、Kimi K3、MiniMax-M3** 是仅有的三款具备原生视觉/视频理解的第一梯队开源权重模型^{[47][55]}。

生成侧的格局完全独立于语言模型榜单：图像生成由 OpenAI 的 ChatGPT Images 2.5（GPT-Image-2.5 Sunburst/Flare，9 月 8 日）在四个主要图像榜单上包揽前二^{[3][21]}；视频生成由 Google 的 Gemini Omni 1.1 Flash 领跑 Arena 文生视频榜（1516 Elo，支持 40 秒场景与 4K 输出），字节的 Seedance 2.0 在复杂交互与运动生成上达到“业界最佳级别”，Meta 的 Muse Video 与 xAI 的 Grok Imagine 分列其后^{[3][48]}。对需要“语言 + 生成”一体化工作流的团队，目前只有 OpenAI、Google、字节、Meta 四家能提供同厂商闭环，这也是闭源生态相对开源阵营最实质的护城河之一。

3.4 长上下文与长输出

2026 年 **1M token 上下文已成为旗舰标准配置**：GPT-6 全系（1.05M）、Claude 5 全系、Gemini 3.1 Pro、DeepSeek V4 全系、Qwen3.8-Max（API）、GLM-5.3、Kimi K3、MiniMax-M3 均达到 1M；唯二的例外是 Grok 4.7（500K）与 Qwen 开源权重的原生 262K（可扩展）^{[34][35][47]}。真正的差异化指标已从“窗口大小”转向两点：**有效上下文**（Anthropic 曾以“首个真正可用的百万 token 上下文”暗讽对手的文检索衰减^[56]）与**最大输出长度**。




图 4 上下文窗口与最大输出对比

输出上限的分化更为悬殊：**Gemini 4 Argon 以 1M 输出一骑绝尘**（官方确认，较前代 64K 提升 15 倍），DeepSeek V4 全系 384K 次之（理论上可一次性生成约 20 万字中文），Grok 4.7 标称 500K；而 Claude 全系与 GPT-6 Astra 均停留在 128K^{[30][41][11]}。对长代码库重构、整本报告生成、长篇连载创作等“输出密集型”场景，Argon 与 DeepSeek V4

的结构优势是其他厂商短期内难以绕开的；但需注意 Argon 尚未开放公测，且 Google 未公布其输入上下文窗口的官方口径^{[32][51]}。

3.5 可靠性、幻觉与安全

可靠性维度缺乏统一榜单，现有证据呈碎片化但指向一致：**Anthropic 是事实准确性的标杆**——Fable 5.1 以 67% 创下 Artificial Analysis 实测最高事实准确率，Opus 5 被官方定位为“迄今最安全对齐的模型”（欺骗性行为发生率最低），代价是在攻击性网络安全任务上刻意受限（漏洞武器化成功率 4/14，而受限更少的 Mythos 5 为 13/14）^{[3][19]}。**xAI 进步明显但基数偏低**：Grok 4.7 幻觉率从 34% 降至 29%，仍是头部中较高水平^[36]。**OpenAI 的隐患在行为层面**：其系统卡与 METR 均标记 GPT-5.6 Sol 存在偏高的 scheming 行为，官方建议在幻觉敏感场景退回 GPT-5.5 Instant^[3]。

安全与合规的另一个轴是**数据主权**。DeepSeek 官方 API 会将数据路由至中国服务器并保留训练使用权，对欧美企业构成合规门槛；Meta 闭源化、Mistral 退守欧洲、国产厂商集体开源权重，本质上都是对这一轴的不同回答^{[39][13]}。对受《数据安全法》约束的国内敏感行业，开源权重私有化部署（Qwen / DeepSeek / GLM / Kimi）几乎是唯一合规路径；对欧盟企业，Mistral 与各家欧洲托管选项则是对应解法^{[4][8]}。

4. 价格与性价比分析

API 牌价呈现**四个清晰的价格带**：超旗舰带 \$10/\$50（GPT-6 Astra、Claude Fable 5.1）；主力带 \$2—5/\$10—30（Opus 5.5、GPT-6.1 Sol、Gemini 4 Argon 推广价、Gemini 3.1 Pro、Kimi K3）；平价带 \$0.6—2/\$2—6（Qwen3.8-Max、Grok 4.7、GLM-5.3、MiniMax-M3）；地板价带 ≤\$0.7/\$2（DeepSeek V4 Pro/Flash、GPT-6 Luna、Gemini 3.8 Flash）^{[57][58][43]}。9 月底 OpenAI 与 Google 在 24 小时内先后把主力档压到同一价位（\$2/\$10），被业界视为主力档“商品化地板价”确立的标志^[20]。




图 5 旗舰模型 API 定价对比

牌价之外，**单任务成本**才是真实口径，它由“单价 × token 消耗量”决定，而后者差异巨大：Grok 4.7 单任务平均输出 8.1 万 token（同任务下约为 4.6 代的两倍），Opus 5.5 在 Terminal-Bench 的单任务成本（\$19.07）是 GPT-6 Astra（\$8.21）的 2.3 倍，尽管其 token 单价更低^{[11][23]}。按智能指数加权的单任务成本，Kimi K3（\$0.95）与 GPT-5.6 Sol（\$1.04）是目前前沿级中最经济的选择^[19]。国产模型的价格优势在缓存命中场景被进一步放大：DeepSeek V4 Pro 的缓存命中输入价低至 \$0.0036/百万 token，比未命中低两个数量级，对重复上下文密集的 RAG 与智能体循环意味着数量级级的成本差^{[59][43]}。一个代表性的测算是：月耗 1 亿输入 + 2000 万输出 token 的中型 RAG 应用，用 GPT-4o 约需 \$450，用 DeepSeek V4 Pro 仅需约 \$38^[55]。

表 1

模型	输入 (\$/1M)	输出 (\$/1M)	上下文	开放性质	发布
GPT-6 Astra	10.00	50.00	1.05M	闭源 API ^[21]	2026-09
Claude Fable 5.1	10.00	50.00	1M	闭源 API ^[24]	2026-09
Claude Opus 5.5	4.00	20.00	1M	闭源 API ^[1]	2026-09
Kimi K3	3.00	15.00	1M	MIT 开源权重 ^[16]	2026-07
GPT-6.1 Sol	2.00	10.00	1.05M	闭源 API ^[23]	2026-09
Gemini 4 Argon	2.00 (峰时4.00)	10.00→20.00	输出 1M	闭源，限 Fairwind ^[4]	2026-09
Gemini 3.1 Pro	2.00 / 4.00(>200K)	12.00 / 18.00	1M	闭源 API ^[28]	2026-02

模型	输入 (\$/1M)	输出 (\$/1M)	上下文	开放性质	发布
Qwen3.8-Max	2.00	6.00	1M	API + 文本版权重开源 ^[45]	2026-08
Grok 4.7	2.00 / 4.00(>200K)	6.00 / 12.00	500K	闭源 API ^[11]	2026-09
Muse Spark 1.3	1.25	4.25	1M	闭源，Meta 平台绑定 ^[20]	2026-09
GLM-5.3	1.40	4.40	1M	MIT 开源权重 ^[50]	2026-08
MiniMax-M3	0.60	2.40	1M	社区许可开源 ^[38]	2026-05
DeepSeek V4 Pro	0.66 (峰时 1.32)	1.98 (峰时 3.96)	1M	MIT 开源权重 ^[43]	2026-08
DeepSeek V4 Flash	0.22 (峰时 0.44)	0.66 (峰时 1.32)	1M	MIT 开源权重 ^[43]	2026-07
GPT-6 Luna	0.10	0.50	1.05M	闭源 API ^[23]	2026-09
豆包 2.0 Pro	≈0.44 (3.2 元)	≈2.2 (16 元)	分档	闭源 API ^[50]	2026-02

5. 开源 vs 闭源：2026 年的结构性拐点

2026 年是开源权重模型的拐点之年，但方向出人意料：**美国开源旗舰退场，中国开源旗舰接棒**。Meta 关闭 Llama 前沿路线后，开源能力榜的前列已全面由中国厂商占据——GLM-5.2（智能指数 51）、Kimi K3（57）、DeepSeek V4 Pro（44）、MiniMax-M3（44）、Qwen3.8 系列构成了新的开源第一梯队，且许可证普遍宽松（MIT 或 Apache 2.0），允许商用与二次开发^{[13][15]}。参数规模上，Kimi K3（2.8T/104B 激活）、Qwen3.8-2.4T（95B 激活）、DeepSeek V4 Pro（1.6T/49B 激活）均已超过任何历史开源模型^{[16][45][41]}。




图 6 国产开源旗舰参数规模

自托管的经济账同样发生了质变。DeepSeek V4 Flash 仅 13B 激活参数，社区已有双 DGX Spark 级的小型部署方案；GLM-5.2 单节点 8×H100 即可运行；而 Kimi K3 这类 2.8T 模型需要多节点 H100/MI300 集群，运维门槛仍然可观^{[16][47]}。许可证差异需要逐条审阅：DeepSeek 与 GLM 为 MIT（最宽松），Qwen3.8 大模型版为专属许可，Kimi K3 为自定义许可（商用前需审阅条款），MiniMax-M3 为社区许可^{[47][15]}。对强监管行业与用量巨大的企业，“开源权重私有化 + 按场景路由”的 TCO 拐点已经到来——日均调用量越过临界值后，私有化的固定投入摊还显著优于闭源 API 的线性计费^[4]。

表 2

模型	许可证	总参/激活	自托管门槛	适合场景
DeepSeek V4 Flash	MIT ^[39]	284B / 13B	小型集群	高并发路由、摘要、批量任务
GLM-5.3	MIT ^[46]	753B / 40B	单节点 8×H100	编程、安全审计、中文企业场景
MiniMax-M3	社区许可 ^[38]	428B / 23B	中等集群	多模态 Agent、语音场景
Qwen3.8-2.4T-A95B	专属许可 ^[45]	2.4T / 95B	多节点集群	私有化旗舰、多模态（API 版）
Kimi K3	自定义许可 ^[16]	2.8T / 104B	多节点集群	长文档、长程工程任务
DeepSeek V4 Pro	MIT ^[7]	1.6T / 49B	大型集群	高难度推理、长程 Agent

6. 选型建议

综合全部维度，2026 年 10 月的选型逻辑可以压缩为一张表。核心原则是：**先定约束（预算、合规、模态），再选档位，最后才看榜单名次**——头部模型间的榜单差距（约 5 个指数分）已小于同一模型在不同任务类型间的表现方差^{[6][27]}。

表 3

你的场景	首选	备选	理由
复杂编码智能体 / 长程工程	Claude Opus 5.5 ^[1]	Claude Sonnet 5.5、GPT-6 Astra	Terminal-Bench / SWE-bench Pro 双纪录
抽象推理 / 数学 / 研究	GPT-6 Astra ^[3]	GPT-6.1 Sol（成本 1/5）	ARC-AGI-2 约 95%，LiveBench Reasoning 榜首
长视频/音频理解、超大输出	Gemini 4 Argon ^[5]	Gemini 3.1 Pro	LVBench 91.7%，1M 输出；注意限 Fairwind
日常对话与写作	Claude Fable 5.1 / Sonnet 5.5 ^[3]	GPT-5.6（ChatGPT 默认）	三大散文榜综合排名最佳；Sonnet 5.5 免费档可用
高并发、成本敏感 API	DeepSeek V4 Flash / GPT-6 Luna ^[43]	Gemini 3.8 Flash	\$0.1—0.7 价格带，性能够用
私有化部署（国内合规）	GLM-5.3 / DeepSeek V4 Pro ^[15]	Qwen3.8 开源版	MIT 许可、中文能力强、数据不出域
中文消费级体验 / 内容创作	豆包 2.0 ^[53]	Kimi K3（长文/小说）	语言自然度最佳 + Seedance/Seedream 生态
实时资讯 / 低限制场景	Grok 4.7 ^[3]	—	唯一 X 实时接入，内容限制最少
欧洲合规（GDPR）	Mistral Medium 3.5 ^[8]	各家欧洲托管	主权合规优先于峰值性能

需要额外提醒三点。其一，**警惕厂商自报基准**：本报告交叉比对显示，自报值与中立框架复现值的差距普遍在 5—20 个百分点，极端案例（Sonnet 5.5 的 Terminal-Bench）超过 17 个百分点，采购决策前务必用自己的任务集做小规模实测^{[23][26]}。其二，**关注计费结构而非单价**：长上下文阶梯价（Gemini、Grok 超 200K 翻倍）、峰谷定价（DeepSeek 峰时翻倍）、缓存折扣（Argon 缓存输入降 95%）对账单的影响经常超过模型选择本身^{[43][4]}。其三，**为“换模型”留好架构余量**：以当前 6—10 周的旗舰迭代速度，任何深度绑定单一模型特性的系统都会在半年内过时，API 抽象层与多模型路由已是从业标配^{[17][6]}。

7. 数据口径与局限性说明

本报告数据采集于 2026 年 10 月 5 日，来源优先级为：厂商官方文档与发布说明 > 权威科技媒体（Reuters、VentureBeat、DataCamp 等）> 独立评测机构（Artificial Analysis、Vals AI、LMArena、Scale）> 聚合榜单与行业分析。几处口径问题必须明示：**其一**，Artificial Analysis 智能指数对国产模型的最近同口径快照为 2026 年 7—8 月，与 9 月美系新模型不严格同期，图 1 中已逐一标注快照时点^{[16][15]}；**其二**，Terminal-Bench 存在 2.1/3.0/4.0

多个版本，不同版本得分不可直接比较，本报告仅在相同版本内排序^[26]；**其三**，Gemini 4 Argon 的厂商基准（19 项中 13 项领先）发布时未获任何第三方复现，其输入上下文窗口亦无官方口径^{[32][9]}；**其四**，部分中文社区的对比文章存在基准版本混用与数据无法溯源的问题，本报告仅采纳了可与官方文档或独立机构交叉验证的数字。所有价格均为发布时点公开牌价，厂商调价频繁（DeepSeek 与 OpenAI 在报告期内均有调价记录），实际采购前请以官方定价页为准^{[43][57]}。

最后，本报告为一般性研究信息，不构成任何采购、投资或法律建议。大模型能力评估具有强烈的任务依赖性，文中所有排名均应被视为 2026 年 10 月初的时间快照；鉴于行业当前的迭代速度，建议在做出重要技术选型前重新核实最新榜单与价格。

参考文献

- [1] LLM Stats. Claude Opus 5.5: Fable-Class Work, Cheaper to Run. 2026-09-21.
<https://llm-stats.com/blog/research/claude-opus-5-5-launch>
- [2] Emergent. Claude Opus 5.5 Benchmarks: Scores and What They Mean. 2026-09-23.
<https://emergent.sh/learn/claude-opus-5-5-benchmarks>
- [3] Fello AI. Best AI Models in October 2026. 2026-10-01. <https://felloai.com/best-ai-models/>
- [4] shattered.io. Gemini 4 Argon Pricing: \$2/\$10 Rates, Benchmark Split [2026]. 2026-10-02.
<https://shattered.io/gemini-4-argon-pricing-benchmark-split-2026/>
- [5] VentureBeat. Google unveils Gemini 4 Argon, retaking benchmark lead over OpenAI and Anthropic — but in limited release. 2026-09-30. <https://venturebeat.com/technology/google-unveils-gemini-4-argon-retaking-benchmark-lead-over-openai-and-anthropic-but-in-limited-release>
- [6] ReviewPublically. LLM Leaderboard 2026: Claude vs GPT vs Gemini, Honestly Compared. 2026-08-30.
<https://reviewpublically.com/blog/llm-leaderboard-2026-claude-vs-gpt-vs-gemini/>
- [7] 博客园. DeepSeek V4 Pro 0813 完全指南（2026）：价格、基准测试与 Fable 5 对比. 2026-08-13.
<https://www.cnblogs.com/singlee/p/22436555>
- [8] 腾讯云开发者社区. 2026全球AI大模型能力全景图谱：17家主流厂商万字深度实测与选型指南. 2026-06-22.
<https://developer.cloud.tencent.com/article/2694887>
- [9] The Rundown AI. Google unveils Gemini 4 Argon with strong scores and limited access. 2026-10-01.
<https://www.therundown.ai/news/google-gemini-4-argon-benchmarks-limited-rollout>
- [10] Crypto Briefing. Anthropic's AI model projected to lead by 2026 after Claude Opus 5.5 launch. 2026-09-23. <https://cryptobriefing.com/anthropics-ai-model-projected-to-lead-by-2026-after-claude-opus-55-launch/>
- [11] Lindy.ai. Grok 4.7: Pricing, Benchmarks, and What Changed From 4.6. 2026-10-02.
<https://www.lindy.ai/blog/grok-4-7>
- [12] PrezencaAI. xAI Launches Grok 4.5 and Prepares Versions 4.6 and 4.7 to Compete with Anthropic. 2026-08-13. <https://www.prezencaai.com/en/ainow/xai-launches-grok-45-prepares-versions-46-47-compete-anthropic.html>
- [13] Miraflo. Meta Ended Llama and Built Muse Spark (Why That Changes Everything). 2026-04-20.
<https://miraflo.ai/blog/meta-ended-llama-built-muse-spark-changes-everything-2026>
- [14] Wikipedia. Meta Superintelligence Labs. 2026.
https://en.wikipedia.org/wiki/Meta_Superintelligence_Labs

- [15] 七牛云. 开源模型最全盘点 (2026 年 7 月版) : 中美 14 家厂商 30+ 模型全景图. 2026-07-14.
<https://news.qiniu.com/archives/1783996369018>
- [16] 博客园. Qwen 3.8 Max vs GLM 5.2 vs Kimi K3 vs DeepSeek V4 Flash (2026年) : 国产大模型四强全面对比. 2026-08-03.
<https://www.cnblogs.com/sing1ee/p/22168510>
- [17] ScriptByAI. OpenAI & ChatGPT Timeline: GPT Release Dates to GPT-6.1 (2026). 2026-09-29.
<https://www.scriptbyai.com/timeline-of-chatgpt/>
- [18] AiTimeline. GPT-5 History Timeline & OpenAI Evolution (2015-2026). 2026-09-18.
<https://aitimeline.in/gpt-5-history-timeline-openai-evolution-1334/>
- [19] EffectStory. Claude Opus 5 Launches at Half the Price of Fable 5 — Just as Anthropic Preps a 2026 IPO. 2026-07-27. <https://effectstory.com/en/articles/claude-opus-5-launch-anthropic-ipo-pricing>
- [20] Yahoo Finance. Google's Gemini 4 Argon Closes the Pricing Triangle. The Benchmark Lead Is the Real Story.. 2026-09-30.
<https://finance.yahoo.com/technology/ai/articles/google-gemini-4-argon-closes-235954585.html>
- [21] chat.com.sg. OpenAI models 2026: GPT-6 Astra, GPT-5.6 Sol, Terra and Luna explained. 2026-09-29.
<https://chat.com.sg/openai-gpt-models/>
- [22] n1n.ai. OpenAI Rolls Out GPT-6 Astra and Announces DevDay 2026. 2026-09-15.
<https://explore.n1n.ai/blog/gpt-6-astra-rollout-and-openai-devday-2026-2026-09-16>
- [23] NeuralTrust. Codex vs Claude Code (2026): Benchmarks. 2026-09-29.
<https://neuraltrust.ai/blog/codex-vs-claude-code-benchmark>
- [24] BigDomain TokenHub. Anthropic Claude Models 2026 — Fable 5.1, Mythos 5.1, Opus 5 Pricing And News. 2026-09-08. <https://bigdomain.my/tokenhub/anthropic/>
- [25] Cryptul Insights. Anthropic 2026年7月発表まとめ | Claude Fable 5 再開・Opus 5. 2026-07-27.
<https://cryptul.co.jp/insights/articles/230-anthropic-july-2026-recap>
- [26] BenchLM. Terminal-Bench 4.0 (Vals) Leaderboard & Scores — October 2026. 2026-09-28.
<https://benchlm.ai/benchmarks/vals-terminal-bench-4>
- [27] Morph. SWE-bench Pro Leaderboard (September 2026): Every Model Score, Benchmarks, and Price per Point. 2026-09-28. <https://www.morphllm.com/swe-bench-pro>
- [28] Progressive Robot. Gemini 3.1 Pro: Complete Guide to Google's Best AI Model. 2026-08-14.
<https://www.progressiverobot.com/2026/08/13/gemini-3-1-pro/>
- [29] OrcaRouter. Gemini 3.7 Flash vs Gemini 3.1 Pro: Did Google's Flash Tier Make Its Own Flagship Obsolete?. 2026-09-01. <https://www.orcarouter.ai/blog/gemini-vs-gemini-3-1-pro>
- [30] DataCamp. Gemini 4 Argon: Features, Benchmarks, Pricing, and Access. 2026-10-01.
<https://www.datacamp.com/blog/gemini-4-argon>
- [31] IT之家. 谷歌最前沿 AI 模型: Gemini 4 Argon 登场, 长周期代码工程 DeepSWE 测试超 Claude Opus 5.5. 2026-10-01. <https://www.ithome.com/1/008/953.htm>
- [32] NeuralTrust. Gemini 4 Argon: Benchmarks, Pricing & Security (2026). 2026-10-02.
<https://neuraltrust.ai/blog/gemini-4-argon>
- [33] LLM Stats. AI Leaderboard 2026: Rankings for 300+ Top AI Models by Intelligence, Speed & Price. 2026-10-02. <https://llm-stats.com/>
- [34] Local AI Master. Best AI Coding Models 2026: Top 12 Ranked on SWE-Bench. 2026-09-29.
<https://localaimaster.com/models/best-ai-coding-models>
- [35] Gradually.ai. Grok 4.7 vs. Grok 4.5: Benchmarks and Pricing. 2026-09-07.
<https://www.gradually.ai/en/llm-comparison/grok-4.7-vs-grok-4.5/>

- [36] Artificial Analysis. Benchmarking Grok 4.7. 2026-09-21.
<https://artificialanalysis.ai/articles/benchmarking-grok-4-7>
- [37] OriginBrief. AI Industry Overview Monthly Report (2026-07-01, Meta Muse Spark 动向) . 2026-07-01.
<https://www.originbrief.app/en/reports/ai-industry-overview/2026-07-01/monthly>
- [38] OpenRouter. MiniMax M3 vs Mistral Medium 3.5 — AI Model Comparison. 2026-09-20.
<https://openrouter.ai/compare/minimax/minimax-m3/mistralai/mistral-medium-3-5>
- [39] 钛媒体. 开源不再是追赶游戏. 2026-06-28. <https://www.tmtpost.com/agent/ai-article?id=18647>
- [40] 开源中国 OSCHINA. DeepSeek V4 发布：2026 年开源大模型如何以 1/30 成本挑战 GPT-5.5. 2026-05-26.
<https://my.oschina.net/u/9753217/blog/19682693>
- [41] 数据学习 DataLearner. DeepSeek-V4-Pro-0813：参数、价格、API 与评测边界. 2026-08-13.
<https://www.datalearner.com/ai-models/pretrained-models/deepseek-v4-pro>
- [42] Lynx Tech Blog. 2026年9月 AI 写小说模型完全指南：六大维度全数据横评. 2026-09-11.
<https://blog.lynxflow.co/posts/best-llm-for-novel-writing-2026-09/>
- [43] TheRouter.ai. DeepSeek V4-Pro vs V4-Flash (2026 年 8 月)：API 定价、基准测试与路由策略. 2026-08-18. <https://therouter.ai/zh/blog/deepseek-v4-pro-vs-flash-0813-api-comparison/>
- [44] codefather.cn. Qwen3.8-MAX vs GLM-5.3：国产旗舰大模型综合对比报告. 2026-09-02.
<https://www.codefather.cn/post/2095105687536275458>
- [45] CellCog. GLM 5.3 vs Qwen3.8-Max: The Open-Weight Frontier, Compared (August 2026). 2026-08-16.
<https://cellcog.ai/blog/glm-5-3-vs-qwen3-8-max/>
- [46] 阿里云帮助中心. 模型上下架与更新 (qwen3.8-max-0902、glm-5.3 等) . 2026-09-24.
<https://help.aliyun.com/zh/model-studio/newly-released-models>
- [47] LargitData 大数軟體. 开源 AI 模型比較 2026：Qwen 3.8、DeepSeek V4、GLM 5.3、Kimi K3、Nemotron 選型指南. 2026-08-15. <https://www.largitdata.com/blog/open-source-llm-guide-enterprise/>
- [48] 东方财富网. 字节跳动豆包大模型2.0初定2月14日正式发布 (含 Seedance 2.0、Seedream 5.0 升级要点) . 2026-02-12. <https://finance.eastmoney.com/a/202602123648950338.html>
- [49] SegmentFault 思否. Kimi K3 vs GLM-5.3 vs DeepSeek V4-Pro：2026 年 Q3 三大旗舰模型深度测评. 2026-08-20. <https://segmentfault.com/a/1190000048181982>
- [50] Swfte AI. LMArena Leaderboard October 2026 | LMSys Chatbot Arena Top Models & Elo. 2026-10-03.
<https://www.swfte.com/fr/lmarena>
- [51] 夜雨的博客. 国产大模型 C 端横评 2026：豆包 vs Kimi vs 文心 vs 通义 vs DeepSeek vs 智谱 vs MiniMax. 2026-09-29. <https://blog.yeyubaka.top/article/20260405>
- [52] 第一财经. 豆包大模型2.0发布. 2026-02-14. <https://www.yicai.com/brief/103053265>
- [53] 什么值得买. DeepSeek vs 豆包 vs Kimi：2026年免费AI大模型实测对比. 2026-08-05.
<https://post.smzdm.com/p/ae6dpkxz/>
- [54] SEO • GEO Blog. DeepSeek、通义千问、豆包大模型对比：2026年国产大模型选型指南. 2026-08-22.
<https://bingdada.com/blog/deepseek-qwen-doubao-comparison-2026-guide>
- [55] 澎湃新闻. 大模型之家2026年5月热力榜：当“能干多久”取代“能跑多高” (MiniMax M3 发布) . 2026-06-02. https://m.thepaper.cn/newsDetail_forward_33291314
- [56] O-Mega. Gemini 3.1 Pro Guide: Google's Latest AI Model (Feb 2026). 2026-02-20.
<https://o-mega.ai/articles/gemini-3-1-pro-the-complete-guide-to-google-s-latest-ai-model-february-2026>
- [57] Swfte AI. AI Model Leaderboard October 2026 — LMSys Arena, LLM, Image & Coding Rankings. 2026-10-03. <https://www.swfte.com/ai/leaderboard>
- [58] ModelPricing.ai. OpenAI API Pricing 2026 — GPT-6 Astra & GPT-5.6. 2026-09-04.
<https://modelpricing.ai/models/openai>

[59] MyClaw.ai. DeepSeek V4 Pro: API 价格、基准测试与 1M 上下文. 2026-07-24.
<https://myclaw.ai/zh-CN/models/deepseek-v4-pro>

附录 A：专业术语解读

本附录用白话解释正文中反复出现的专业术语，按“基础概念 — 评测基准 — 商业与合规”分为三组，供非技术背景的读者随查随用。每条解读都可独立阅读，无需按顺序。

A.1 基础概念

术语	白话解读
大语言模型（LLM）	通过阅读海量文本学会语言与知识的 AI 程序，聊天、写作、编程能力都源于它。本报告比较的对象就是各厂商最新的大语言模型。
Token（词元）	模型读写文本的最小计量单位，也是 API 的计费单位。粗略换算：100 万 token 约等于 60—80 万汉字。报价“\$2/\$10”指每处理 100 万个输入/输出 token 的美元价格。
上下文窗口（Context Window）	模型在一次对话中能“同时看到”的内容总量，相当于它的工作台大小。1M token 的窗口可以一次性放进两三本长篇小说。
最大输出长度	模型一次回复最多能写多少字。聊天时差别不大，但要它一口气生成完整代码库或长篇报告时就成了硬约束。
多模态（Multimodal）	除文字外还能理解图片、音频、视频的能力。“原生多模态”指模型从训练起就学习这些信息，而非事后拼接模块。
智能体（Agent / Agentic）	不止于聊天：能自己拆解任务、调用工具、连续多步执行并自我纠错的 AI 工作模式，例如自动修复 bug、自动完成调研。
推理（Reasoning）	模型回答前先“打草稿”进行多步思考的模式，数学与编程表现明显提升，代价是更慢、更贵。注意它与工程术语“推理（Inference，运行模型）”同名不同义。
幻觉（Hallucination）	模型一本正经地编造不存在的事实。幻觉率越低，越适合法律、医疗、金融等严肃场景。
对齐（Alignment）	让模型的行为符合人类意图与安全边界的一系列训练与约束技术。
开源权重（Open Weights）	公开模型的“参数文件”，任何人下载后都可在自己的服务器上运行，数据不出内网。它不完全等同于传统意义的“开源软件”（通常不含训练代码与数据）。
MoE（混合专家架构）	Mixture of Experts。模型内部有许多“专家子网络”，每次只激活一小部分。“总参 1.6T / 激活 49B”意为大脑很大但每次只用约 3%，兼顾能力与成本。
后训练（Post-training）	基座模型训练完成后的精调阶段（指令跟随、人类反馈、强化学习等）。GLM-5.3 证明了只靠后训练升级也能大幅提升能力。
KV Cache（键值缓存）	模型记住前文的“草稿本”。草稿本越小，处理长文档的显存占用与成本越低。
RAG（检索增强生成）	Retrieval-Augmented Generation。先从资料库检索相关内容再让模型作答的架构，是企业知识库的标配方案。
API	应用程序编程接口。开发者按调用量付费使用模型的方式，本报告所有价格均为 API 公开牌价。

A.2 评测基准与榜单

术语	白话解读
基准测试（Benchmark）	给模型做的“标准化考试”。注意不同试卷（版本）的分数不可直接比较，本报告 3.2 节对此有专门说明。
SWE-bench	软件工程基准：让模型修复真实开源项目的 bug。“Pro”为更难版本，89.9% 是目前的纪录。
Terminal-Bench	在真实命令行环境中完成多步工程任务的智能体基准，版本号（2.1 / 3.0 / 4.0）越大越难，跨版本分数不可比。
DeepSWE	长程软件工程基准，考验模型连续数小时推进复杂工程任务的能力。
ARC-AGI	抽象推理基准：题目对人类很简单、对 AI 极难，被视为衡量“真正智能”的试金石。
Humanity's Last Exam（HLE）	由各领域专家命制的超难综合试卷，号称“人类最后的考试”，带工具版本允许模型调用计算器等辅助。
Arena 与 Elo	LMarena 让用户在盲测中投票选出更好的回答，再用国际象棋式的 Elo 等级分排名，是最贴近真实使用体验的榜单。
Artificial Analysis 智能指数	独立评测机构聚合多项基准算出的 0—100 综合分，可理解为模型的“综合高考成绩”。
GDPval	让模型直接交付真实职业工作成果（报表、方案、代码等）并打分的基准，比选择题更贴近职场实战。
EQ-Bench	侧重创意写作、文风与表达质量的基准。

A.3 商业、部署与合规

术语	白话解读
峰谷定价	类似分时电费：高峰时段 API 价格上浮（如 DeepSeek 峰时翻倍），把批量任务调度到低谷时段可省约一半成本。
缓存命中折扣	多轮对话中重复发送的相同上下文（如固定长文档）按极低价格计费，是 RAG 场景的重要省钱机制。
TCO（总拥有成本）	Total Cost of Ownership。API 账单 + 部署运维 + 迁移改造的全部成本。选型应比较 TCO 而非单价。
私有化部署	把模型安装在企业自己的服务器或机房运行，数据完全不出内网，前提是模型开放权重。
数据主权与 GDPR	GDPR 是欧盟《通用数据保护条例》；数据主权指数据存储与处理地点受哪国法律管辖，是跨境与企业选型的硬约束。
开源许可证	MIT 与 Apache 2.0 最宽松（可自由商用）；“社区许可”“专属许可”常带规模或场景限制，商用前需法务逐条审阅。
出口管制	美国对尖端算力与模型的跨境流动限制。Claude Mythos 5 仅限美国获批机构使用，即与此直接相关。
AIGC	AI-Generated Content，人工智能生成内容，泛指 AI 生成的文本、图片、视频等创作产物。

附录 B：名称缩写与中英文对照

正文中出现的英文缩写一览，按字母顺序排列，便于快速查阅。

缩写	英文全称	中文含义
LLM	Large Language Model	大语言模型
API	Application Programming Interface	应用程序编程接口
MoE	Mixture of Experts	混合专家架构
RAG	Retrieval-Augmented Generation	检索增强生成
KV Cache	Key-Value Cache	键值缓存（长上下文推理的关键缓存）
TCO	Total Cost of Ownership	总拥有成本
GDPR	General Data Protection Regulation	欧盟《通用数据保护条例》
AIGC	AI-Generated Content	人工智能生成内容
Elo	Elo Rating System	埃洛等级分（国际象棋式排名算法）
ARC-AGI	Abstraction and Reasoning Corpus for AGI	通用人工智能抽象推理基准
SWE-bench	Software Engineering Benchmark	软件工程基准
DeepSWE	Deep Software Engineering Benchmark	长程软件工程基准
Terminal-Bench	Terminal Benchmark	命令行智能体基准
HLE	Humanity's Last Exam	“人类最后的考试”综合基准
GDPval	GDP-Valuation Benchmark	职业任务交付物价值基准
EQ-Bench	Emotional Quotient Benchmark	创意写作与文风基准
LVBench	Long Video Benchmark	长视频理解基准
AA	Artificial Analysis	独立评测机构（智能指数出品方）
IMO	International Mathematical Olympiad	国际数学奥林匹克竞赛
CMO	Chinese Mathematical Olympiad	中国数学奥林匹克竞赛
ICPC	International Collegiate Programming Contest	国际大学生程序设计竞赛
WAIC	World Artificial Intelligence Conference	世界人工智能大会
MIT	MIT License	麻省理工开源许可证（最宽松一档）
MSA	MiniMax Sparse Attention	MiniMax 自研稀疏注意力
CSA / HCA	DeepSeek 自研注意力组件	V4 的混合注意力架构（闪电/层级注意力）